ISSN (Online) 2747-0563
Volume 4 Tahun 2024

Klasifikasi Penyakit Daun Kentang Menggunakan Metode ResNet50

Muhammad Ahsanur Rafi[1], Budi Nugroho[2], Chrystia Aji Putra[3]

[1,2,3] Teknik Informatika, Universitas Pembangunan Nasional "Veteran" Jawa Timur

21081010305@student.upnjatim.ac.id

ajiputra@upnjatim.ac.id

*Corresponding author email: budinugroho.if@upnjatim.ac.id

Abstrak* — Penyakit pada daun tanaman kentang, seperti Early Blight dan Late Blight, merupakan ancaman serius bagi produktivitas pertanian yang dapat menyebabkan penurunan kualitas dan kuantitas hasil panen secara signifikan. Penelitian ini bertujuan untuk mengimplementasikan teknologi deep learning guna mengklasifikasikan jenis penyakit tersebut secara otomatis dan akurat. Metode yang diusulkan dalam penelitian ini menggunakan arsitektur ResNet50 yang telah melalui proses transfer learning dan dioptimasi menggunakan teknik augmentasi data untuk meningkatkan variasi dataset. Dataset citra daun kentang yang digunakan dibagi menjadi tiga kategori utama, yaitu training, validation, dan testing. Berdasarkan hasil pengujian yang telah dilakukan menggunakan Google Colab dengan akselerasi GPU T4, model ResNet50 berhasil mencapai tingkat akurasi sebesar 82,72% pada data pengujian. Hasil ini menunjukkan bahwa penggunaan arsitektur ResNet50 sangat efektif dalam mengenali pola penyakit pada daun kentang. Dengan demikian, sistem ini diharapkan dapat membantu petani dalam melakukan deteksi dini penyakit tanaman secara lebih cepat dibandingkan metode manual, sehingga tindakan pengendalian dapat dilakukan dengan lebih tepat sasaran.

Kata Kunci— **ResNet50, Deep Learning, Transfer Learning, Klasifikasi Citra, Penyakit Daun Kentang.**

I. PENDAHULUAN

Kentang (*Solanum tuberosum*) merupakan komoditas umbi-umbian yang memegang peranan vital sebagai sumber karbohidrat alternatif fungsional selain beras, terutama karena karakteristik kandungan glukosanya yang relatif rendah sehingga aman bagi kesehatan [1]. Di wilayah Jawa Timur, tren produksi kentang menunjukkan peningkatan yang signifikan dari tahun 2023 ke 2024, yang mengindikasikan potensi besar tanaman ini dalam mendukung ketahanan pangan nasional [2]. Namun, stabilitas produktivitas ini sangat bergantung pada kualitas kesehatan tanaman, terutama organ daun sebagai tempat utama berlangsungnya proses fotosintesis.

Ancaman serius terhadap hasil panen kentang umumnya berasal dari serangan patogen jamur yang menyebabkan penyakit *early blight* dan *late blight* [3]. Kedua jenis penyakit ini tidak hanya menurunkan kuantitas produksi, tetapi juga berisiko menghasilkan senyawa toksik yang membahayakan konsumen. Oleh karena itu, kemampuan untuk mengidentifikasi gejala infeksi secara dini menjadi langkah strategis guna meminimalisir kerugian ekonomi bagi petani [4]. Secara visual, gejala penyakit dapat dikenali melalui anomali warna, bentuk, dan tekstur pada permukaan daun [5].

Pemanfaatan teknologi pengolahan citra digital kini menjadi solusi mendesak untuk menggantikan metode inspeksi manual yang bersifat subjektif dan membutuhkan waktu lama [6]. Implementasi metode *deep learning* terbukti memiliki keandalan tinggi dalam mendeteksi pola penyakit yang kompleks dibandingkan metode konvensional, terutama jika dilatih menggunakan representasi data yang beragam [7]. Beberapa arsitektur jaringan saraf tiruan seperti InceptionV3 telah menunjukkan performa luar biasa dalam mengekstraksi fitur multiskala dengan tingkat akurasi tinggi pada berbagai dataset penyakit tanaman [8]. Sementara itu, model yang lebih ringan seperti MobileNetV3 menawarkan efisiensi komputasi yang ideal untuk implementasi pada perangkat dengan sumber daya terbatas di lapangan [9]. Penelitian ini berfokus pada pengembangan sistem klasifikasi otomatis untuk penyakit daun kentang guna memberikan hasil diagnosis yang cepat, akurat, dan efisien.

II. TINJAUAN PUSTAKA

A. Tanaman Kentang

Kentang (*Solanum tuberosum* L.) diakui sebagai komoditas pangan esensial global yang kaya akan nutrisi dan senyawa fungsional, serta memiliki peran strategis dalam menjaga ketahanan pangan berkat adaptabilitas agroekologinya yang luas. Meskipun demikian, stabilitas hasil panen kentang terus terancam oleh gangguan patologis utama seperti *early blight* dan *late blight* yang mampu memicu kerusakan serius dan menurunkan produktivitas hingga 70% jika tidak ditangani dengan tepat[10].

Penyakit early blight akibat jamur Alternaria solani menyerang jaringan daun tua dengan pola nekrotik konsentris yang

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

dipengaruhi oleh faktor iklim serta status nutrisi kalium tanaman [11]. Di sisi lain, late blight yang dipicu oleh Phytophthora infestans menjadi ancaman paling destruktif karena kemampuannya merusak organ daun, batang, hingga umbi secara cepat pada kondisi lembap, sehingga integrasi teknologi analisis spektral red edge dan model prediksi cuaca kini diandalkan untuk melakukan monitoring lapangan yang akurat [12].

B. Deep Learning

Implementasi *deep learning* melalui arsitektur Jaringan Saraf Konvolusional (CNN) memungkinkan sistem untuk mengekstraksi fitur hirarkis secara otomatis langsung dari data citra mentah, sehingga mampu mengenali gejala penyakit tanaman yang sangat halus tanpa memerlukan intervensi manual dalam penentuan parameter fitur. Teknologi ini telah membuktikan keunggulannya dalam menangani kompleksitas visual pada data pertanian, memberikan performa yang jauh lebih stabil dan akurat dibandingkan metode pengolahan citra konvensional dalam proses diagnosis otomatis di lapangan [13].

C. Arsitektur ResNet50

Implementasi arsitektur ResNet50 dalam penelitian ini memanfaatkan konsep *residual learning* yang menggunakan mekanisme *shortcut connections* untuk memitigasi kendala *vanishing gradient* pada jaringan saraf yang sangat dalam, sehingga proses pembaruan bobot tetap stabil selama fase pelatihan. Struktur blok residual tersebut memungkinkan model untuk mempertahankan integritas informasi spasial saat melakukan ekstraksi fitur yang lebih mendalam, yang sangat krusial dalam mengenali karakteristik mikroskopis dan detail tekstur pada citra penyakit daun kentang, seperti pola cincin konsentris pada *Early Blight* atau lesi nekrotik pada *Late Blight* [14].

D. Transfer Learning

Transfer learning merupakan skema pembelajaran mesin yang merepurpos model *pre-trained* dari basis data general untuk diterapkan pada domain tugas yang lebih spesifik. Proses ini melibatkan adaptasi bobot awal melalui tahap *fine-tuning* guna menyesuaikan model dengan karakteristik *dataset* target. Dalam identifikasi patologi tanaman, pendekatan ini sangat krusial untuk mengatasi kelangkaan data citra dengan memanfaatkan ekstraksi fitur dasar seperti tepi, tekstur, dan bentuk yang telah mapan pada model sebelumnya. Dengan mengimplementasikan *fine-tuning* pada lapisan akhir jaringan saraf tiruan (CNN), akurasi klasifikasi dapat ditingkatkan secara signifikan tanpa harus bergantung pada volume data yang masif atau intensitas komputasi yang tinggi [15].

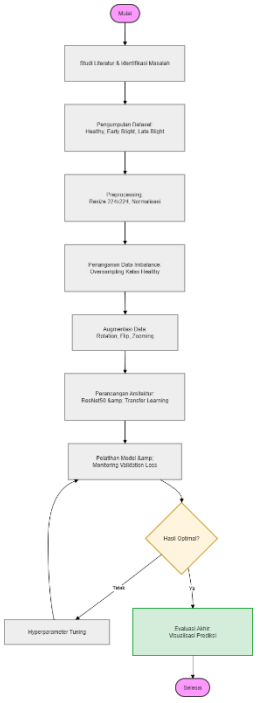
E. Augmentasi Data

Augmentasi data merupakan teknik krusial dalam memperluas volume serta variabilitas dataset pelatihan untuk memitigasi isu ketidakseimbangan data dan mencegah terjadinya *overfitting*. Salah satu strategi yang dapat diimplementasikan adalah *image-to-image translation*, yang mentransformasikan citra orisinal menjadi data baru dengan karakteristik visual berbeda tanpa mengubah esensi objek yang direpresentasikan. Pendekatan ini sering kali mengintegrasikan mekanisme *attention* guna mengarahkan fokus ekstraksi fitur pada area penting citra, didukung oleh teknik *background preservation* untuk menjaga konsistensi elemen latar belakang. Melalui skema ini, dihasilkan citra sintetis dengan tekstur yang lebih beragam, sehingga model klasifikasi dalam identifikasi penyakit daun kentang memiliki kemampuan generalisasi yang lebih representatif terhadap kondisi riil di lapangan [16].

F. Metrik Evaluasi dan Monitoring Loss

Penilaian efektivitas model dalam mengklasifikasikan penyakit tanaman dilakukan melalui analisis metrik performa komprehensif, yang meliputi akurasi, presisi, *recall*, dan *F1-score* sebagai indikator keberhasilan deteksi pada setiap kategori. Selain penggunaan metrik tersebut, proses monitoring fungsi kerugian (*loss function*) selama fase pelatihan menjadi sangat krusial untuk mengawasi konvergensi dan stabilitas model. Pengamatan terhadap pergerakan *validation loss* memungkinkan implementasi mekanisme *model checkpoint* yang berfungsi untuk mengamankan bobot terbaik, sehingga meminimalisir risiko *overfitting* dan menjamin kemampuan generalisasi model saat diuji dengan data citra dari kondisi lapangan yang beragam [17].

III. *DESAIN DAN IMPLEMENTASI SISTEM*



Gbr. 1 Tahapan Alur Penelitian

A. *Studi Masalah dan Identifikasi Masalah*

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

Proses penelitian ini dimulai dengan melakukan studi literatur mendalam terhadap perkembangan teknologi *deep learning*, khususnya arsitektur *Convolutional Neural Network* (CNN) berbasis ResNet50 yang terbukti efektif memitigasi kendala *vanishing gradient* melalui mekanisme *residual learning*. Berdasarkan tinjauan pustaka tersebut, diidentifikasi bahwa klasifikasi penyakit daun kentang—yang mencakup kategori *Early Blight*, *Late Blight*, dan *Healthy*—memiliki tantangan teknis berupa kemiripan tekstur visual pada fase awal infeksi yang memerlukan ekstraksi fitur sangat detail. Selain kompleksitas fitur, identifikasi masalah utama dalam penelitian ini adalah adanya ketidakseimbangan data (*data imbalance*), di mana jumlah sampel citra daun sehat cenderung lebih terbatas dibandingkan citra yang terinfeksi patogen, sehingga berisiko menyebabkan model menjadi bias dalam melakukan prediksi. Oleh karena itu, penelitian ini mengintegrasikan strategi *transfer learning* dan teknik *oversampling* guna mengatasi hambatan tersebut, dengan target mencapai performa klasifikasi yang optimal dan reliabel untuk mengenali kondisi tanaman di lapangan.

B. *Pengumpulan Dataset*

Tahap pengumpulan dataset dilakukan dengan memperoleh data sekunder berupa *Potato Disease Leaf Dataset (PLD)* yang dipublikasikan oleh Rizwan Saeed pada tahun 2021. Dataset ini terdiri dari 4.072 total gambar, citra digital daun kentang yang telah diklasifikasikan ke dalam tiga kategori utama, yaitu *Healthy*, *Early Blight*, dan *Late Blight*. Penggunaan dataset PLD ini bertujuan untuk menyediakan variasi fitur visual yang memadai bagi arsitektur *ResNet50* dalam mempelajari karakteristik patologi tanaman, mulai dari tekstur hingga pola perubahan warna pada permukaan daun. Citra-citra tersebut menjadi basis data primer dalam proses pelatihan model guna mencapai target akurasi yang optimal, serta menjadi landasan bagi tahap prapemrosesan dan penanganan ketidakseimbangan data melalui teknik *oversampling*.

C. *Preprocessing Data*

Tahap prapemrosesan (*preprocessing*) merupakan langkah krusial untuk menyeragamkan format data citra sebelum diinputkan ke dalam arsitektur model. Dalam penelitian ini, seluruh citra dari *Potato Disease Leaf Dataset* (PLD) melalui tahap *resizing* menjadi dimensi 224x224 piksel. Penyesuaian dimensi ini dilakukan guna menyelaraskan ukuran citra dengan standar *input layer* pada arsitektur *ResNet50*, sehingga proses ekstraksi fitur pada lapisan konvolusi dapat berjalan secara konsisten. Selain penyesuaian dimensi, dilakukan pula proses normalisasi nilai piksel citra dengan mengubah rentang nilai aslinya (0–255) ke dalam skala numerik antara 0 hingga 1. Teknik normalisasi ini bertujuan untuk menyeimbangkan distribusi data, mempercepat konvergensi selama fase pelatihan, serta memastikan stabilitas gradien.



Gbr. 2 Alur Preprocessing Data

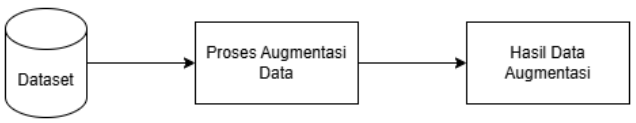
D. *Penanganan Data Imbalance*

Tahap selanjutnya dalam alur penelitian ini adalah penanganan ketidakseimbangan data (*data imbalance*) yang teridentifikasi pada *Potato Disease Leaf Dataset* (PLD). Ketidakseimbangan ini terjadi karena jumlah sampel citra pada kelas *Healthy* memiliki kuantitas yang lebih rendah dibandingkan dengan kelas *Early Blight* dan *Late Blight*. Untuk mengatasi hambatan tersebut, diterapkan teknik *oversampling* pada kelas minoritas guna menyamakan distribusi jumlah data antar kategori. Langkah ini sangat krusial untuk mencegah model menjadi bias terhadap kelas mayoritas, sehingga arsitektur *ResNet50* dapat mempelajari fitur dari setiap kelas secara adil dan menyeluruh. Implementasi strategi ini menjadi salah satu faktor kunci dalam meningkatkan kemampuan generalisasi model.

E. Augmentasi Data

Setelah tahap penanganan ketidakseimbangan data, dilakukan proses augmentasi data menggunakan fungsi *ImageDataGenerator* untuk meningkatkan variabilitas dataset pelatihan secara artifisial tanpa mengubah label asli citra. Teknik augmentasi yang diterapkan mencakup transformasi geometris berupa rotasi citra sebesar 20 derajat (*rotation_range*), pergeseran lebar dan tinggi sebesar 10% (*width/height shift*), distorsi sudut sebesar 8% (*shear_range*), serta perbesaran citra hingga 15% (*zoom_range*).

Selain transformasi posisi, diterapkan pula manipulasi visual berupa penyesuaian kecerahan dalam rentang 0.85 hingga 1.15 (*brightness_range*) dan pergeseran saluran warna sebesar 8.0 (*channel_shift_range*) untuk menyimulasikan variasi pencahayaan dan intensitas warna di lingkungan lahan pertanian. Penggunaan fitur *horizontal flip* dan mekanisme *fill_mode reflect* memastikan transisi piksel pada area kosong hasil transformasi tetap terlihat alami. Seluruh kombinasi teknik ini bertujuan untuk mencegah terjadinya *overfitting* serta membekali arsitektur *ResNet50* agar lebih tangguh (*robust*) terhadap perbedaan kondisi pengambilan data di lapangan



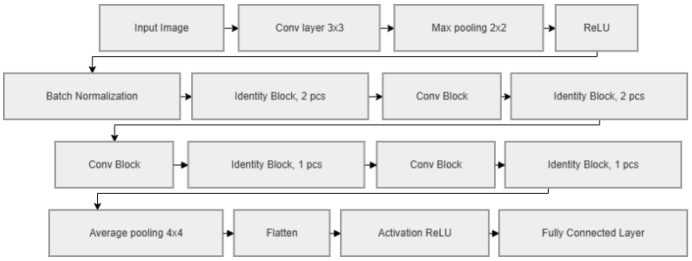
Gbr. 3 Alur Augmentasi Data

F. *Perancangan Arsitektur ResNet50*

Tahap inti dari desain sistem ini adalah implementasi arsitektur *ResNet50* dengan strategi *Transfer Learning*. Dalam penelitian ini, digunakan model *pre-trained* ResNet50 yang telah memiliki bobot (*weights*) dari dataset ImageNet untuk mengenali fitur visual dasar seperti garis dan tekstur. Lapisan

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

Fully Connected pada bagian akhir arsitektur dimodifikasi dan disesuaikan agar mampu mengklasifikasikan citra ke dalam tiga kelas. Penggunaan strategi ini memungkinkan proses pelatihan berjalan lebih efisien dengan waktu komputasi yang lebih singkat namun tetap mampu mengekstraksi fitur kompleks dari patologi daun kentang secara mendalam.



Gbr. 4 Arsitektur ResNet50

G. *Pelatihan Model dan Monitoring Validation Loss*

Proses pelatihan model dilakukan dalam dua tahap terpisah guna mencapai konvergensi yang optimal. Tahap pertama (Phase 1: *Feature Extraction*) dijalankan selama 40 *epoch* dengan membekukan seluruh lapisan *base model* ResNet50 dan menggunakan *learning rate* sebesar 1 x 10^{-3}. Pada fase ini, pemantauan dilakukan melalui metrik *validation accuracy* untuk memastikan model mulai mengenali pola dasar pada citra daun kentang.

Memasuki tahap kedua (Phase 2: *Fine-Tuning*), pelatihan diperpanjang selama 30 *epoch* dengan membuka kunci pada dua blok konvolusi terakhir dan menurunkan *learning rate* menjadi 1 x 10^{-5}. Pada fase ini, protokol pemantauan diubah secara spesifik dengan menitikberatkan pada *validation loss* sebagai parameter utama dalam fungsi *ModelCheckpoint*. Kebijakan ini diambil karena nilai *validation loss* terbukti memberikan representasi stabilitas model yang lebih baik dibandingkan akurasi yang cenderung fluktuatif (*noisy*) selama proses *fine-tuning*. Selain itu, diterapkan mekanisme *ReduceLROnPlateau* untuk menyesuaikan bobot secara adaptif saat perkembangan *loss* mengalami stagnasi. Strategi pemantauan berbasis *loss* ini memastikan model yang disimpan adalah versi dengan kemampuan generalisasi terbaik.

H. Hyperparameter Tuning

Tahap *hyperparameter tuning* dilakukan untuk menentukan kombinasi parameter yang paling optimal guna meningkatkan kemampuan generalisasi model dalam mengklasifikasikan penyakit daun kentang. Dalam penelitian ini, digunakan *Adam Optimizer* dengan pengaturan *clipnorm* sebesar 1,0 untuk menjaga stabilitas pembaruan gradien selama proses pelatihan. Pengaturan *learning rate* dilakukan secara adaptif melalui dua fase pelatihan, yaitu 1 x 10^{-3} pada fase *feature extraction* dan 1 x 10^{-5} pada fase *fine-tuning*. Untuk mencegah terjadinya *overfitting*, diterapkan teknik regularisasi berupa *Dropout* dengan tingkat 0,3 dan 0,2 pada lapisan *fully connected*, serta penggunaan *label smoothing* sebesar 0,1 pada fungsi kerugian (*loss function*) fase kedua untuk memperhalus distribusi probabilitas target. Selain itu, digunakan ukuran *batch* sebesar 32 dan mekanisme *ReduceLROnPlateau* yang secara otomatis menurunkan *learning rate* sebesar 50% apabila *validation loss* tidak menunjukkan penurunan selama 5 hingga 6 *epoch*.

I. Evaluasi Akhir (Visualisasi Prediksi)

Tahap terakhir dalam alur penelitian ini adalah pengujian dan evaluasi kinerja arsitektur ResNet50 menggunakan data uji (*test set*) yang belum pernah dilibatkan dalam fase pelatihan. Evaluasi ini difokuskan pada visualisasi prediksi, di mana hasil klasifikasi dari model dipetakan dan dianalisis secara representatif. Instrumen utama yang digunakan dalam tahap ini adalah visualisasi *Confusion Matrix*, yang memetakan perbandingan secara grafis antara label sebenarnya (*ground truth*) dengan label hasil prediksi model untuk ketiga kelas penyakit daun kentang.

Melalui visualisasi matriks ini (baik dalam bentuk *raw count* maupun distribusi probabilitas yang dinormalisasi), dapat diidentifikasi secara detail seberapa akurat model mengenali kelas *Healthy*, *Early Blight*, dan *Late Blight*, serta mendeteksi area misklasifikasi yang mungkin terjadi antar kelas yang memiliki kemiripan tekstur. Selain itu, visualisasi grafik pergerakan akurasi dan *loss* selama pelatihan juga dievaluasi untuk mengkonfirmasi tidak adanya indikasi *overfitting*. Pendekatan visualisasi prediksi ini memberikan analisis yang komprehensif dan transparan mengenai kemampuan generalisasi model saat diimplementasikan pada data baru.

IV. HASIL DAN PEMBAHASAN

A. *Persiapan Data*

Tahap persiapan data mendeskripsikan hasil implementasi dari proses pengumpulan, partisi, dan prapemrosesan dataset sebelum diumpankan ke dalam arsitektur model. Secara keseluruhan, total 4.072 citra dari *Potato Disease Leaf Dataset* (PLD) telah berhasil didistribusikan ke dalam tiga himpunan utama, yaitu data latih (*training*), data validasi (*validation*), dan data uji (*testing*). Berdasarkan evaluasi distribusi kelas pada direktori data latih, terkonfirmasi adanya ketidakseimbangan (*data imbalance*) yang memicu eksekusi teknik *oversampling* secara terprogram. Proses ini berhasil menduplikasi sampel citra pada kelas minoritas (*Healthy*) hingga kuantitasnya sejajar dengan kelas *Early Blight* dan *Late Blight*.

Setelah distribusi data pada himpunan pelatihan mencapai titik keseimbangan, seluruh himpunan data diproses melalui *pipeline* pemuatan data (*ImageDataGenerator*). Hasil dari *pipeline* ini memverifikasi bahwa seluruh citra telah berhasil diubah dimensinya menjadi 224x224 piksel dan dinormalisasi ke dalam skala 0–1. Data latih yang kini telah seimbang dan melewati proses augmentasi visual tersebut kemudian

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

dikelompokkan ke dalam *batch* berukuran 32. Terbacanya seluruh sampel data pada ketiga himpunan oleh sistem menunjukkan bahwa dataset telah sepenuhnya siap dan divalidasi untuk memasuki fase pelatihan model ResNet50. Rincian distribusi jumlah citra setelah dilakukan proses oversampling dapat dilihat pada Tabel berikut.

Tabel I Rincian Oversampling pada Data Latih (*Training Set*)

Kelas	Sebelum oversampling	Proses Augmentasi	Sesudah Oversampling
Early Blight	1303	0	1303
Late Blight	1132	0	1132
Healthy	816	+487	1303
Total Data	3251	+487	3738

B. *Perancangan Model*

Implementasi perancangan model berhasil dibangun menggunakan arsitektur dasar ResNet50 yang diinisialisasi dengan bobot *pre-trained* dari ImageNet. Pada proses inisialisasi ini, lapisan *input* jaringan telah disesuaikan untuk menerima format citra berdimensi 224x224 piksel dengan tiga saluran warna (RGB). Berdasarkan hasil kompilasi sistem, seluruh lapisan konvolusi bawaan (*base model*) pada tahap awal berhasil dibekukan (*frozen*) guna mempertahankan kemampuan ekstraksi fitur visual dasar. Modifikasi utama yang direalisasikan pada arsitektur ini terletak pada penambahan *custom head* di lapisan atas (*top layers*). Sistem berhasil mengintegrasikan mekanisme *Dual Pooling*, yang menggabungkan fitur keluaran dari *Global Average Pooling* (GAP) dan *Global Max Pooling* (GMP) secara konkatenasi.

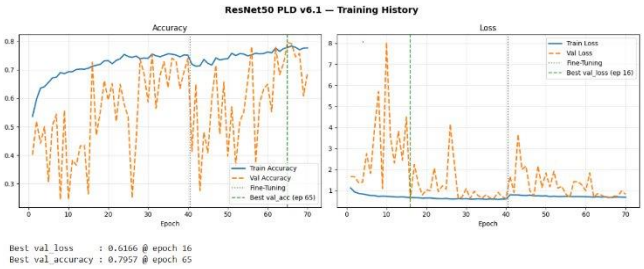
Lapisan klasifikasi buatan tersebut kemudian diteruskan ke dalam jaringan saraf tiruan yang terdiri dari dua lapisan *fully connected* (lapisan *Dense*) dengan ukuran masing-masing 512 dan 256 unit. Untuk menjaga stabilitas perhitungan matematis dan mereduksi risiko *overfitting* selama pelatihan, pada masing-masing lapisan *Dense* telah disematkan fungsi *Batch Normalization* serta *Dropout* dengan rasio 0,3 dan 0,2. Pada terminal akhir jaringan, diimplementasikan lapisan *Dense* berukuran 3 unit dengan fungsi aktivasi *Softmax* yang merepresentasikan probabilitas keluaran untuk ketiga kelas target: *Healthy*, *Early Blight*, dan *Late Blight*. Arsitektur model ini telah berhasil dikompilasi menggunakan *Adam Optimizer*, menghasilkan struktur jaringan utuh yang siap untuk dieksekusi pada fase pelatihan.

```
Total params: 25,820,547 (98.50 MB)
Trainable params: 2,231,299 (8.51 MB)
Non-trainable params: 23,589,248 (89.99 MB)
```

Gbr. 5 Detail Jumlah Parameter dari *Summary*

C. *Analisis Proses Pelatihan Model*

Dinamika pembelajaran model selama proses pelatihan direpresentasikan melalui grafik pergerakan nilai akurasi dan kerugian (*loss*), baik pada data latih maupun data validasi di setiap *epoch*-nya. Berdasarkan visualisasi grafik pelatihan pada Gambar 6, kurva pembelajaran secara jelas terbagi ke dalam dua fase utama. Pada fase pertama (*Feature Extraction*), terlihat kurva akurasi latih dan validasi mengalami peningkatan awal yang signifikan. Hal ini menunjukkan bahwa pemanfaatan bobot *pre-trained* ImageNet berhasil mempercepat konvergensi model dalam mengenali fitur dasar citra daun kentang, meskipun seluruh lapisan dasar (*base model*) masih dalam keadaan dibekukan (*frozen*).



Gbr. 6 Grafik Training

Memasuki fase kedua (*Fine-Tuning*) yang ditandai dengan garis batas vertikal pada grafik, model dituntut untuk beradaptasi dengan pola patologi yang lebih spesifik. Pada fase ini, terlihat bahwa kurva *validation accuracy* cenderung fluktuatif (*noisy*) pada beberapa *epoch* tertentu. Fluktuasi ini merupakan respons wajar akibat pembukaan kunci (*unfreeze*) pada blok konvolusi terakhir dan penyesuaian bobot secara dinamis. Meskipun demikian, kurva *validation loss* justru menampilkan pergerakan yang jauh lebih stabil dan secara konsisten menurun. Penurunan *loss* yang stabil ini membuktikan efektivitas mekanisme *ReduceLROnPlateau* dalam menurunkan *learning rate* secara otomatis ketika terjadi stagnasi. Melalui analisis grafik ini, dapat divalidasi bahwa keputusan untuk menggunakan metrik *validation loss* sebagai acuan utama pada fungsi *ModelCheckpoint* adalah langkah yang tepat, karena sistem terbukti berhasil menangkap dan menyimpan bobot model terbaik tepat pada titik *error* terendah sebelum terindikasi adanya *overfitting*.

D. *Evaluasi Model*

Tahap evaluasi model merupakan pembuktian kinerja akhir dari arsitektur ResNet50 yang telah dilatih, menggunakan

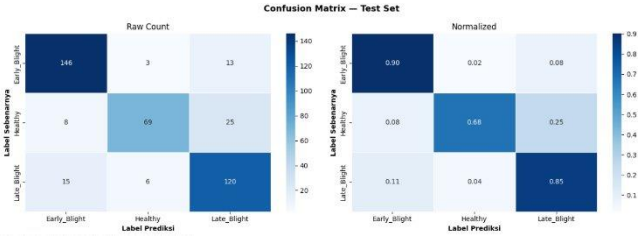
ISSN (Online) 2747-0563
Volume 4 Tahun 2024

himpunan data uji (*testing set*) sebanyak 405 citra yang sama sekali belum pernah diakses oleh sistem selama fase pelatihan maupun validasi. Berdasarkan pengujian akhir, model klasifikasi penyakit daun kentang ini berhasil mencatatkan nilai akurasi pengujian (*test accuracy*) sebesar 82,72%, diiringi dengan nilai *test loss* yang terkendali. Pencapaian tingkat akurasi ini mengonfirmasi bahwa penyesuaian *hyperparameter*, penerapan teknik augmentasi, serta strategi *fine-tuning* dua fase berbasis pemantauan *validation loss* secara efektif mampu membangun kemampuan generalisasi model yang baik saat dihadapkan pada representasi visual data baru.

Tabel II Classification Report

Kelas	Precision	Recall	F1-Score
Early Blight	0.8639	0.9012	0.8822
Healthy	0.8846	0.6765	0.7667
Late Blight	0.7595	0.8511	0.8027
Akurasi Keseluruhan	0.8272		
Rata-rata Makro	0.8360	0.8096	0.8172
Rata-rata Tertimbang	0.8328	0.8272	0.8254

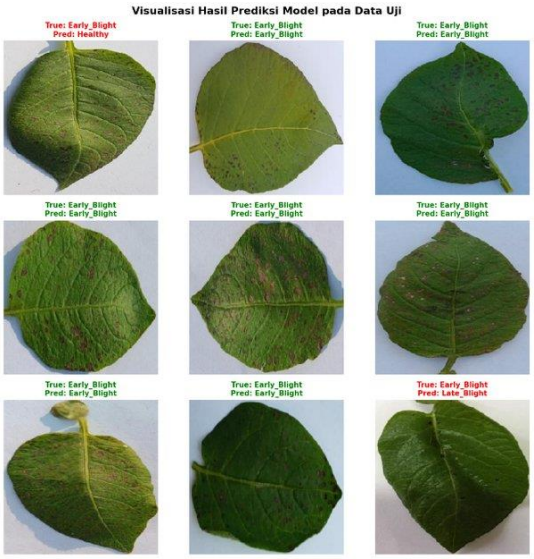
Analisis kinerja yang lebih mendalam dan spesifik ditelaah melalui visualisasi prediksi menggunakan *Confusion Matrix*. Melalui pemetaan matriks tersebut, distribusi ketepatan prediksi model terhadap label sebenarnya (*ground truth*) pada ketiga kategori kelas dapat dievaluasi secara transparan. Secara umum, model menunjukkan sensitivitas dan tingkat kepresisian yang tinggi dalam mengidentifikasi daun kategori *Healthy*, serta mampu membedakannya dari daun yang terinfeksi patogen. Meskipun arsitektur telah mengekstraksi fitur secara mendalam, visualisasi matriks juga memperlihatkan adanya sejumlah kecil misklasifikasi yang terjadi antara sampel kelas *Early Blight* dan *Late Blight*. Fenomena ini wajar terjadi mengingat kedua kelas penyakit tersebut memiliki kemiripan karakteristik bercak visual pada fase perkembangan infeksi tertentu. Namun demikian, secara keseluruhan metrik performa membuktikan bahwa model yang dirancang memiliki keandalan (*reliability*) yang memadai untuk berfungsi sebagai sistem diagnostik otomatis penyakit tanaman kentang.



Gbr. 7 Confusion Matrix

E. *Visualisasi Hasil Prediksi*

Untuk melengkapi analisis kuantitatif pada tahapan evaluasi sebelumnya, pengujian kualitatif dilakukan melalui visualisasi langsung terhadap representasi sampel citra dari himpunan data uji (*testing set*). Visualisasi ini memetakan perbandingan antara label kelas sebenarnya (*ground truth*) dengan label hasil tebakan jaringan (*predicted label*) yang dihasilkan oleh arsitektur ResNet50. Berdasarkan sampel prediksi yang terklasifikasi dengan benar (*True Positives*), model terbukti memiliki kepekaan spasial yang baik dalam mengekstraksi fitur patologis. Model berhasil mengisolasi area bercak cokelat konsentris yang menjadi ciri khas *Early Blight*, serta mendeteksi penyebaran area nekrotik tidak beraturan yang menandakan infeksi *Late Blight*. Pada kelas *Healthy*, model secara akurat mengidentifikasi tekstur daun yang normal tanpa terdistraksi oleh variasi sudut pengambilan gambar.



Gbr. 8 Sampel Data Uji

Selain mengonfirmasi keberhasilan model, visualisasi hasil prediksi ini juga membedah kasus-kasus misklasifikasi (*false*

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

predictions) yang selaras dengan temuan penurunan *recall* pada *Confusion Matrix*. Pada beberapa sampel pengujian, daun dari kelas *Healthy* diprediksi secara keliru sebagai daun terinfeksi akibat adanya faktor *noise* visual pada citra. Bayangan gelap pada lipatan daun, pantulan cahaya yang tidak merata, atau kerusakan mekanis minor pada pinggiran daun kerap diinterpretasikan oleh lapisan konvolusi sebagai bercak patogen awal. Lebih lanjut, pada kasus misklasifikasi silang antara penyakit *Early Blight* dan *Late Blight*, visualisasi citra menunjukkan bahwa daun yang berada pada fase infeksi parah atau fase transisi memiliki karakteristik kerusakan jaringan yang sangat ambigu dan tumpang tindih. Meskipun terdapat sejumlah kecil anomali prediksi tersebut, secara keseluruhan representasi visual ini menegaskan bahwa model mampu menggeneralisasi pemahaman visualnya dengan sangat baik, menjadikannya sistem yang adaptif dan dapat diandalkan untuk mendeteksi penyakit daun kentang di luar skenario pelatihan.

V. KESIMPULAN

Berdasarkan keseluruhan tahapan perancangan, pelatihan, dan evaluasi yang telah dilakukan pada penelitian ini, dapat ditarik beberapa kesimpulan utama. Pertama, penelitian ini telah berhasil merancang dan mengimplementasikan model *Deep Learning* berbasis arsitektur ResNet50 dengan menerapkan strategi *Transfer Learning* untuk mengklasifikasikan tiga kondisi daun kentang: *Healthy*, *Early Blight*, dan *Late Blight*. Modifikasi arsitektur pada lapisan atas (*top layer*) melalui mekanisme *Dual Pooling*—yang menggabungkan fitur dari *Global Average Pooling* dan *Global Max Pooling*—terbukti efektif dalam mengekstraksi baik informasi latar belakang secara global maupun titik dominan patologi penyakit secara spesifik. Selain itu, penerapan teknik *oversampling* pada tahap prapemrosesan berhasil menanggulangi isu ketidakseimbangan kelas (*data imbalance*), sehingga mendukung konvergensi model yang lebih baik selama proses pelatihan dua fase (*feature extraction* dan *fine-tuning*).

Kedua, pengujian kualitatif dan kuantitatif terhadap model menunjukkan hasil yang menjanjikan, di mana sistem berhasil mencapai tingkat akurasi pengujian sebesar 82,72% dengan nilai *test loss* sebesar 0,6277. Berdasarkan rincian metrik evaluasi, model mencatatkan performa identifikasi paling superior pada kelas *Early Blight* dengan *F1-score* mencapai 0,8822. Meskipun sistem telah menunjukkan sensitivitas yang tinggi, analisis *Confusion Matrix* mengungkap adanya tantangan moderat pada kelas *Healthy*, di mana beberapa sampel keliru terprediksi sebagai daun terinfeksi akibat adanya gangguan (*noise*) visual bawaan citra seperti bayangan gelap atau kerusakan fisik minor. Secara keseluruhan, perancangan arsitektur yang dipadukan dengan pemantauan *validation loss* pada pengoptimal Adam ini telah menghasilkan model diagnostik yang stabil, adaptif, dan memiliki kemampuan generalisasi yang baik terhadap data visual baru.

REFERENSI

[1] Lutfi and D. U. Hafriana, 'Analisis Kadar Glukosa pada Kentang Rebus (Solanum Tuberosum) sebagai Pengganti Nasi bagi Penderita Diabetes Melitus dengan Menggunakan Spektrofotometri', *Jurnal Media Laboran*, vol. 10, no. 1, pp. 26–31, 2020.

[2] Badan Pusat Statistik, 'Produksi Tanaman Sayuran dan Buah-buahan Semusim Menurut Provinsi dan Jenis Tanaman — 2024'. Accessed: Sep. 01, 2025. [Online]. Available: https://www.bps.go.id/assets/statistics-table/3/ZUhFd1JtZzJWVVpqWTJsV05XTllhVmhRSzFoNFFUMDkjMw==/produksi-tanaman-sayuran-dan-buah-buahan-semusim-menurut-provinsi-dan-jenis-tanaman----2024.html?year=2024

[3] L. Meno, O. Escuredo, M. S. Rodríguez-Flores, and M. C. Seijo, 'Modification of the tomcast model with aerobiological data for management of potato early blight', *Agronomy*, vol. 10, no. 12, 2020, doi: 10.3390/agronomy10121872.

[4] A. M. Lesmana, R. P. Fadhillah, and C. Rozikin, 'Identifikasi Penyakit pada Citra Daun Kentang Menggunakan Convolutional Neural Network (CNN)', *Jurnal Sains dan Informatika*, vol. 8, no. 1, pp. 21–30, 2022, doi: 10.34128/jsi.v8i1.377.

[5] P. S. A. P. Wulandari, K. T. Martono, and I. P. Windasari, 'Pengembangan Sistem Pendeteksi Gesture Angka pada Tangan secara Realtime Berbasis Android', *Edu Komputika Journal*, vol. 7, no. 1, pp. 1–9, 2020, doi: 10.15294/edukomputika.v7i1.38655.

[6] F. Agustina and Z. A. Ardiansyah, 'Identifikasi Citra Daging Ayam Kampung dan Broiler Menggunakan Metode GLCM dan Klasifikasi-NN Image Identification of Local Chicken Meat and Broiler Chicken Meat Using GLCM Method and K-NN Classification', *25 Jurnal Infokam*, vol. XVI, no. 1, 2020.

[7] P. H. Kyaw, J. Gutierrez, and A. Ghobakhlou, 'A Systematic Review of Deep Learning Techniques for Phishing Email Detection', *Electronics (Switzerland)*, vol. 13, no. 19, 2024, doi: 10.3390/electronics13193823.

[8] T. D. Salka, M. B. Hanafi, S. M. S. A. A. Rahman, D. B. M. Zulperi, and Z. Omar, 'Plant leaf disease detection and classification using convolution neural networks model: a review', *Artif. Intell. Rev.*, vol. 58, no. 10, 2025, doi: 10.1007/s10462-025-11234-6.

[9] A. B. Ayyappan, T. Gobinath, M. Kumar, and A. Sivaramakrishnan, 'Rice Plant Disease Detection using Convolutional Neural Networks', *Discover Artificial Intelligence*, vol. 5, no. 1, 2025, doi: 10.1007/s44163-025-00277-x.

[10] J. Xu, Y. Li, L. Kaur, J. Singh, and F. Zeng, 'Functional Food Based on Potato', *Foods*, vol. 12, no. 11, 2023, doi: 10.3390/foods12112145.

[11] L. Meno, I. K. Abuley, O. Escuredo, and M. C. Seijo, 'Suitability of Early Blight Forecasting Systems for Detecting First Symptoms in Potato Crops of NW Spain', *Agronomy*, vol. 12, no. 7, pp. 8–12, 2022, doi: 10.3390/agronomy12071611.

[12] C. I. Fernández, B. Leblon, A. Haddadi, K. Wang, and J. Wang, 'Potato late blight detection at the leaf and canopy levels based in the red and red-edge spectral regions', *Remote Sens. (Basel).*, vol. 12, no. 8, pp. 1–27, 2020, doi: 10.3390/RS12081292.

[13] N. Mishra *et al.*, 'Cell suspension culture and in vitro screening for drought tolerance in soybean using poly-ethylene glycol', *Plants*, vol. 10, no. 3, pp. 1–20, Mar. 2021, doi: 10.3390/plants10030517.

[14] T. Boonmee, L. Wongthaveethong, C. Sinpoo, T. Disayathanoowat, J. S. Pettis, and V. Chaimanee, 'Surface Modification of Materials by Atmospheric-Pressure Plasma to Improve Impregnation with Essential Oils for the Control of Tropilaelaps Mites in Honeybees (Apis mellifera)', *Applied Sciences (Switzerland)*, vol. 12, no. 12, Jun. 2022, doi: 10.3390/app12125800.

ISSN (Online) 2747-0563
Volume 4 Tahun 2024

[15] W. Shafik, A. Tufail, C. De Silva Liyanage, and R. A. A. H. M. Apong, 'Using transfer learning-based plant disease classification and detection for sustainable agriculture', *BMC Plant Biol.*, vol. 24, no. 1, pp. 1–19, 2024, doi: 10.1186/s12870-024-04825-y.
[16] B. Min, T. Kim, D. Shin, and D. Shin, 'Data Augmentation Method for Plant Leaf Disease Recognition', *Applied Sciences (Switzerland)*, vol. 13, no. 3, pp. 1–17, 2023, doi: 10.3390/app13031465.
[17] J. Trini, H. P. Maurer, J. E. Neuweiler, and T. Würschum, 'Identification and fine-mapping of quantitative trait loci controlling plant height in central european winter triticale (×triticosecale wittmack)', *Plants*, vol. 10, no. 8, Aug. 2021, doi: 10.3390/plants10081592.